

Radar de licitaciones que lee el pliego

Un agente que mira cada día las licitaciones públicas que se publican en España, abre el pliego de las que encajan con una empresa y le dice a cuáles puede presentarse, con la frase exacta del pliego y la página en la que está.

Este documento explica qué hace, cómo lo hace y qué se midió. Está escrito para alguien que no ha visto nunca el proyecto. Todas las cifras salen de una medición que se puede repetir con un comando, y las que salieron en contra de la tesis también están aquí.

Lo que hay dentro

Expedientes cargados de la Plataforma de Contratación	124.902
Adjudicaciones con su ganador	218.982
Pliegos descargados y guardados por su huella	108
Requisitos extraídos con cita comprobada	62
Pruebas automáticas que lo vigilan	332
Gastado en el modelo desde el primer día	2,23 €

1. El problema, con números

En España se publican cada día cientos de licitaciones públicas. En el semestre que usa este estudio se publicaron **120.656 expedientes en 181 días con publicaciones, 666 al día de media**. Una empresa pequeña que quiera vender al sector público tiene que encontrar entre todo eso las pocas a las que puede presentarse.

Lo que se hace hoy es filtrar por código CPV, que es la etiqueta temática que lleva cada anuncio. Es rápido y es lo que hace todo el mundo, pero tiene dos problemas. El primero es que el CPV lo pone el organismo que publica y no siempre acierta. El segundo es más de fondo: **el anuncio no dice si la empresa cumple los requisitos**. Eso está en el pliego, que es un PDF de cincuenta páginas de media, y ahí es donde se dice que hay que facturar 93.000 € al año, o tener una certificación concreta, o haber hecho antes tres trabajos parecidos.

Así que alguien de la empresa abre uno por uno los pliegos de las candidatas, busca la cláusula de solvencia, la lee y decide. Ese trabajo es el que hace el radar.

Qué es exactamente un pliego

El pliego de cláusulas administrativas (PCAP) es el documento que fija las reglas del concurso: quién puede presentarse, qué hay que acreditar y cómo se valora. Es donde está la frase que decide si una empresa puede o no puede presentarse, del tipo:

«Requisito mínimo de solvencia: El volumen anual de negocios referido al mejor ejercicio dentro de los tres últimos disponibles será de, al menos, 93.000,00 euros.»

Página 52 de 77 · Junta de Gobierno del Ayuntamiento de Pozuelo de Alarcón · expediente 2024/PA/041

Esa cita no es un ejemplo inventado para este documento: es de un pliego que el radar ha leído, está guardada en la base de datos y se puede comprobar abriendo ese PDF por esa página.

Una empresa que facture más de esa cifra cumple; una que facture menos, no. El radar busca esa frase, la copia literal, apunta en qué página estaba y compara los dos números. Ni resume, ni interpreta, ni redondea.

2. Cómo funciona, paso a paso

El radar no es «una pregunta a una inteligencia artificial». Son ocho pasos, y el modelo de lenguaje solo interviene en dos de ellos. Todo lo que decide algo lo decide un programa con reglas escritas y leíbles.

Paso	Qué hace	¿Usa el modelo de lenguaje?
1. Ingesta	Descarga el feed de la Plataforma de Contratación del Sector Público y guarda cada fichero tal cual llegó, identificado por su huella digital.	No
2. Triage	Con lo que dice el anuncio (objeto, órgano, CPV), decide si la licitación puede interesar a esta empresa: sí, no o duda. Van veinte licitaciones en cada pregunta.	Sí, un modelo barato

3. Descarga del pliego	De las que han pasado el filtro, baja el PDF del pliego.	No
4. Localizar	Busca en qué páginas del pliego está la cláusula de solvencia. Puntúa cada página por las palabras que contiene y se queda con un tramo corto.	No
5. Extraer	Lee solo esas páginas y copia los requisitos, cada uno con su cita literal y su número de página.	Sí, el modelo bueno
6. Comprobar	Busca esa cita, letra por letra, en el texto de esa página. Si no aparece, el requisito no se usa para decidir nada.	No
7. Decidir	Compara lo que pide el pliego con lo que declara la empresa y dictamina: puede presentarse, no puede, o hay que mirarlo a mano.	No
8. Ficha y correo	Escribe una página con la decisión y sus motivos, y compone el correo de la mañana.	No

La regla de oro: el modelo extrae, el programa decide

Esta separación es la decisión más importante del proyecto. Un modelo de lenguaje es bueno encontrando una frase dentro de un documento largo y es malo como fuente de verdad: si se le pregunta «¿puede esta empresa presentarse?», contesta algo razonable aunque se lo esté inventando, y no hay forma de saberlo.

Por eso al modelo solo se le pide que **copie**: «dime qué requisitos de solvencia hay en estas páginas, y de cada uno dame la frase exacta y la página». Lo que hace después el programa es buscar esa frase en esa página. Si no está —porque el modelo la ha resumido, la ha juntado de dos sitios o se la ha inventado— **el requisito se cae y no cuenta**. Se le pide una vez más y, si vuelve a fallar, ese requisito no participa en la decisión y queda escrito que no se pudo comprobar.

La comparación de los dos números tampoco la hace el modelo. La hace un fichero de reglas de cincuenta líneas que cualquiera puede leer, y que además está limitado a propósito: **lo único que puede descartar una licitación es el volumen de negocios**, porque es la única comparación que es de verdad dos números. Todo lo demás —una certificación, una clasificación empresarial, experiencia previa— manda la licitación a «hay que mirarlo a mano». Nunca la descarta en silencio.

3. Lo que recibe la empresa

Cada mañana llega un correo con las licitaciones del día, una por línea, con la decisión delante. Al pie va lo que se ha mirado y lo que ha costado. Un día sin nada también manda correo diciendo que no hay nada: el silencio no se distingue de una avería.

Radar de licitaciones · Empresa del Norte · 28-09-2026

— PUEDE PRESENTARSE
 Suministro de licencias de software
 Ayuntamiento de ejemplo · expediente 2026/1
 De 1 requisito leído del pliego: 1 cumple.

Se han mirado 400 licitaciones, 37 pasaron el primer filtro.
El radar lee el pliego y cita lo que dice. La decisión de presentarse es tuya.

Las dos cifras del pie son las de la última pasada de verdad; la licitación del ejemplo está inventada para enseñar el formato, y por eso el órgano se llama «Ayuntamiento de ejemplo».

Detrás de cada línea hay una ficha con los requisitos encontrados. Cada uno lleva tres cosas juntas: **la frase literal del pliego, el número de página y el enlace al PDF original**. Eso es lo que hace que la ficha se pueda comprobar en treinta segundos: se abre el PDF, se va a esa página y se busca la frase. Si está, el radar dice la verdad; si no está, el radar tiene un fallo y se ve enseguida.

La ficha está diseñada para que se distingan dos voces. Lo que dice el pliego va en letra con remate (serif) y entre comillas; lo que dice el radar, en letra de palo seco. Un sello azul marca las citas que el programa ha comprobado contra el PDF, y uno de color óxido las que no se pudieron comprobar. Nunca hay que adivinar qué parte es del documento oficial y qué parte es del programa.

Y la frase que cierra todas las fichas

«El radar lee el pliego y cita lo que dice. La decisión de presentarse es tuya.» No es una fórmula de cortesía: el radar no sabe si a la empresa le compensa el margen, si tiene equipo libre ese mes o si quiere entrar en ese cliente. Solo lee requisitos.

4. Qué se midió, y qué salió

Un proyecto que dice «funciona» sin enseñar cómo lo sabe no vale nada. Aquí el método se escribió y se subió al repositorio **antes** de mirar ningún dato, y el orden de los commits es la prueba de que no se cambió después. Se midieron tres cosas.

4.1. Qué modelo usar para el filtro barato

Se probaron tres formas de hacer el triaje sobre 200 licitaciones de dos empresas, con la regla de decisión escrita de antemano: «si la diferencia de aciertos es menor de ocho puntos, gana la más barata».

Variante probada	Aciertos	Licitaciones que deja pasar	Coste por 100
Modelo barato, de 20 en 20	24 de 24	37,9 y 53,0 de 100	0,0403 €
Modelo barato, de una en una	24 de 24	7,6 y 53,0 de 100	0,1845 €
Modelo caro, de 20 en 20	24 de 24	60,6 y 68,2 de 100	0,1888 €

Las tres aciertan lo mismo, así que gana la barata: **4,7 veces más barata que la cara y además deja pasar menos ruido**. Sin la regla escrita antes, la tentación habría sido quedarse con el modelo caro «por si acaso».

4.2. Si el radar se inventa citas

Esta es la medida que sostiene todo lo demás, porque si las citas no son de fiar, la ficha es una opinión con formato bonito. De **62 requisitos extraídos de 15 pliegos reales, los 62 tenían una cita que aparece literal en la página que dijo el modelo. El 100 %**, con cero rechazos.

Que el rechazo sea cero no significa que la comprobación no haga nada: si se desactiva, dos tests se ponen en rojo inmediatamente porque una cita inventada pasaría. Significa que el modelo copia bien cuando se le dan las páginas exactas contra las que se le va a comprobar. De paso: se leen **4,7 páginas de las 51,5** que tiene un pliego de media, el 9 %. Ahí está el coste bajo.

4.3. Si el radar encuentra más contratos que un filtro CPV

Esta era la tesis del proyecto. Se cogieron cinco empresas reales que no se habían tocado nunca, sus 77 contratos ganados de verdad, y se miró cuántos habría encontrado el radar y cuántos dos filtros rivales.

Comparación	Radar	Rival	Diferencia	Intervalo de confianza
Frente al filtro CPV estándar	74,0 %	81,8 %	-7,8 puntos	[-23,4, +7,8] → no concluyente
Frente al filtro hecho a medida	74,0 %	88,3 %	-14,3 puntos	[-26,0, -3,9] → tesis refutada

La tesis salió refutada. El radar encuentra menos contratos que un filtro de CPV bien hecho, y se publica así porque para eso se congeló el criterio antes de medir. Cambiar la tesis después de ver el resultado habría sido convertir el estudio en publicidad.

4.4. Por qué pierde, medido y no supuesto

De los 77 contratos, el radar descartó 20. **Diecinueve de esos veinte son productos o servicios que el perfil de la empresa no menciona.** Una distribuidora cuya web solo habla de una marca ganó once contratos de licencias de otras dos; una integradora que se describe montando equipos de televisión ganó contratos de analítica de redes sociales. El modelo razonó bien sobre una descripción demasiado estrecha.

El techo del radar no es el modelo: es lo poco que sabe de la empresa. Y eso cambia qué hay que arreglar. No hace falta un modelo mejor ni más páginas leídas; hace falta preguntarle a la empresa lo que no cuenta de sí misma.

5. La consecuencia: un formulario que pregunta lo que nadie cuenta

La medición señaló el arreglo, y el arreglo está hecho. Una empresa entra en el radar rellenando un formulario, y de lo que escribe sale el texto que lee el modelo. El formulario no es una caja de texto libre, por un motivo concreto: **nadie escribe de sí mismo lo que no cree importante.** Una distribuidora describe lo que fabrica, no las marcas que revende, y ahí estaban los contratos perdidos.

Por eso pregunta suelto, y tres preguntas llevan escrito por qué se hacen:

La pregunta	Por qué está ahí
Marcas y productos que distribuye, instala o mantiene	Aquí estaban 19 de los 20 contratos que el radar dejó escapar en la medición.
Otros servicios que presta, aunque no sean su bandera	La formación, el soporte o el suministro de terminales dan contratos y no suelen salir en la web de la empresa.

Lo que no hace

Para que un descarte sea una decisión con motivo y no un silencio.

Cuánto está dispuesta a gastar al día

Leer un pliego cuesta dinero. Sin este tope, el radar tendría que decidir por la empresa cuántos abre.

Cada empresa tiene su propio tope diario y recibe su propio correo. El trabajo de la mañana se corta por ese tope, y se corta leyendo pliegos, nunca triando: quedarse sin triar significa no haber mirado una licitación que quizá era la buena, mientras que quedarse sin leer solo deja un pliego para el día siguiente.

6. Lo que cuesta

Todo lo que se le pide al modelo pasa por un único fichero que apunta los tokens, el coste en dólares y en euros, y comprueba el presupuesto **antes** de llamar: cuenta los tokens de entrada, que es gratis, y supone que la respuesta saldrá al máximo. Es una estimación pesimista a propósito: más vale negarse de más que gastar de más.

Concepto	Medido
Triar 100 licitaciones	0,04 €
Leer un pliego entero, con su cita verificada	0,070 € de media
Un día de trabajo de una empresa con tope de 1 €	hasta 11 pliegos leídos
Todo el proyecto, desde el primer día	2,23 € en 290 llamadas

El coste bajo no sale de usar un modelo malo: sale de no leer lo que no hace falta. De las 51,5 páginas de un pliego se leen 4,7, porque un programa sin modelo localiza antes dónde está la cláusula de solvencia.

7. Cómo está construido

El dato va siempre en la misma dirección y cada capa solo conoce la anterior. Cualquier fila de la base se puede remontar hasta el fichero exacto que la produjo.

feed de la Plataforma
→ capa de ficheros tal cual llegaron, con su huella
→ tabla intermedia
→ núcleo (licitaciones, lotes, adjudicaciones)
→ agente (triaje, pliego, ficha)
→ evaluación

Pieza	Para qué	Por qué esta y no otra
Python + PostgreSQL	Todo el radar y su base de datos.	Lo que hay que poder demostrar es la trazabilidad, y eso es SQL.

LangGraph	El grafo que va de una licitación candidata a una ficha.	Por sus ramas: sin pliego, sin sección de solvencia, el modelo contestando cualquier cosa, el salto al anexo. Y porque guarda el paso a paso: si algo se cae a la mitad, se ve en qué nodo estaba.
n8n	El reloj de las siete de la mañana y el envío del correo.	El aviso tiene que salir aunque el que falle sea el propio radar. Si el correo lo mandara el agente, un fallo del agente sería también un fallo del aviso.
Claude	Dos pasos: el triaje y la extracción de requisitos.	Uno barato para mirar mucho y uno bueno para leer poco y bien.

Cómo se comprueba que no está roto

Hay **332 pruebas automáticas**, y la regla al arreglar un fallo es siempre la misma: primero se escribe la prueba que falla por ese fallo, se comprueba que está en rojo, y solo entonces se arregla. El mensaje del commit dice qué fallaba y cómo se demostró, no solo qué se cambió.

Además hay una matriz de fallos escrita de antemano —qué debe pasar si el PC está apagado a las siete, si la Plataforma no responde, si el pliego es una imagen escaneada, si el modelo contesta algo ilegible— con una prueba por fila. Al escribirlas aparecieron tres fallos reales que no se habrían visto de otro modo. El mejor: **la ingesta diaria se habría comido su propia copia del feed** y, a partir del segundo día, habría devuelto cero licitaciones nuevas sin dar ningún error.

Estado actual: 410.864 filas de licitación, 18.312 expedientes vigentes con el plazo abierto y 62 requisitos extraídos, de los que 62 tienen su cita comprobada contra la página.

8. Los errores que costaron dinero o habrían mentido

Esta sección está aquí porque es la parte más útil del proyecto. Todos estos fallos son reales, todos se encontraron durante el desarrollo y todos tienen hoy una prueba que se pone en rojo si vuelven.

Qué fallaba	Qué habría pasado
El coste se contaba una vez por licitación en lugar de una por llamada.	Una llamada de 0,10 € se apuntaba como 0,40 €. Con veinte licitaciones por llamada, el presupuesto del día se agotaba veinte veces antes de tiempo.
El buscador de páginas se llevaba el índice y la parte técnica.	En un pliego real de 112 páginas leía las páginas 1 a 7 mientras la cláusula de solvencia estaba en la 54. Pagaba por leer y no encontraba nada.
Una llamada pagada podía quedarse sin apuntar.	Se llamó al modelo caro, se pagó, y el registro falló después . Gasto real que el presupuesto no veía, que es justo lo que el presupuesto existe para evitar.
Volver a leer un pliego duplicaba sus requisitos.	La ficha repetía el mismo requisito una vez por lectura y el correo decía «de 4 requisitos leídos: 4 cumplen» de un pliego que tenía uno.

Un tope de «1.00 €» se guardaba como 100 €.

Dos trozos del programa leían los números de forma distinta. El cliente pedía gastar un euro al día y el radar entendía cien.

El correo sumaba el gasto de todos los clientes.

Cada empresa habría visto en su correo lo que gastaron las demás.

9. Lo que el radar no hace

Un sistema que no dice dónde falla no se puede usar para decidir nada. Estos límites están escritos en la especificación del proyecto, no aparecieron después.

Límite	Qué significa
El techo es el perfil de la empresa	Medido: 19 de los 20 contratos perdidos eran productos que el perfil no nombraba. Si el perfil está mal, la decisión también.
Un pliego escaneado no se lee	Si el PDF no trae texto, el expediente sale como «hay que mirarlo a mano» diciendo que es una imagen. No se inventa su contenido.
Las casillas marcadas no se leen	Muchos pliegos son formularios con casillas, y el texto extraído no conserva cuál está marcada. Se avisa; no se adivina.
Solo la Plataforma estatal	Varias comunidades autónomas publican en su propia plataforma y esas licitaciones no se ven.
Solvencia con medios externos o en unión de empresas	La ley permite acreditar solvencia apoyándose en otras empresas. No se modela.
Ganar no es presentarse	La verdad de referencia son los contratos ganados. No se sabe a qué más se presentó cada empresa, así que la precisión solo se estima.
Los perfiles del estudio los escribió el modelo	Salen solo de fuentes públicas y sin mirar ni un contrato, pero quedan más ordenados que el perfil que escribiría un cliente real, y eso favorece al radar. Es el sesgo más importante del estudio.

10. Qué demuestra este proyecto

No demuestra que leer el pliego encuentre más contratos que un filtro de CPV. Eso se midió y salió que no, y está publicado con su intervalo de confianza.

Demuestra otras cuatro cosas, y las cuatro son comprobables abriendo el repositorio:

Que se puede impedir que un modelo mienta

Obligándole a citar y comprobando la cita contra el documento. 62 de 62 citas verificadas.

Que se puede medir de verdad	Congelando el método antes de mirar los datos, con el orden de los commits como prueba, y publicando el resultado aunque salga en contra.
Que un diagnóstico vale más que un resultado bonito	La medición no solo dijo que la tesis fallaba: dijo dónde. 19 de 20 contratos perdidos por lo mismo, y de ahí salió el formulario que lo arregla.
Que el coste se puede controlar	Todo el proyecto, desde la primera línea, por debajo de lo que cuesta un café. Cada llamada apuntada, cada euro atribuible a quien lo gastó.

La frase que mejor resume el proyecto es la que cierra cada ficha que genera:

«El radar lee el pliego y cita lo que dice. La decisión de presentarse es tuya.»

11. Cómo se pone en marcha

Todo arranca con tres contenedores —la base de datos, el orquestador y el propio radar— y se maneja con comandos que se pueden leer. Ninguno de ellos gasta dinero salvo el que lo dice.

```
docker compose up -d
uv run python -m radar.diagnostico    # ¿está todo en su sitio?
uv run python -m radar.ingesta --paginas 10
uv run python -m radar.diario         # qué haría hoy y qué costaría
uv run python -m radar.diario --gastar # hacerlo
uv run pytest                        # todas las pruebas
```

El comando sin **--gastar** no llama al modelo: dice cuántas licitaciones hay por mirar, cuántos pliegos se podrían abrir con lo que queda del tope y cuánto costaría cada uno. Que la opción por defecto sea la que no gasta no es un detalle: es la misma idea que recorre el proyecto entero, que una cosa que cuesta dinero se hace a propósito y no por descuido.

12. En qué punto está

Las siete fases de construcción están cerradas, cada una con su informe y con el comando que reproduce sus cifras. El trabajo diario por cliente funciona de punta a punta: la última pasada real trió **400 licitaciones** publicadas y dejó **37 candidatas**, y hay una prueba automática que recorre la cadena entera —alta de la empresa, triaje, pliego en PDF, comprobación de la cita, ficha y correo— sin saltarse ningún paso.

Lo que falta no es código: es tiempo. La prueba de que esto aguanta son cinco días laborables seguidos recibiendo el correo de la mañana, y eso solo se consigue esperando cinco días.

El código está en un repositorio con todo el historial: los informes de cada fase, las decisiones técnicas con su motivo, los documentos de método congelados antes de medir y los commits que demuestran que se congelaron antes.